建筑结构引导的区域表征与跨事件检索增强光学—SAR 建筑损毁评估

编写说明：本稿依据用户提供的《光学 SAR 建筑损毁论文初稿 20261014.docx》及其中图 1—图 3 改写。不采用初稿或聊天记录中的任何性能数值、排名及提升结论。所有“【待填】”均为尚待真实实验回填的位置；方法描述是待验证的设计，不等于已实现、已完成或已证实有效。实验编号和执行细节见配套《实验与配图规划》。已访问过的 Test 应在最终协议中如实记录，不能重新称为从未使用的盲测集。

摘要

灾前光学影像与灾后合成孔径雷达影像为建筑损毁评估提供互补观测，但跨模态融合后的像素表示仍面临区域组织与损毁判别之间的匹配问题。一方面，仅依据局部外观和空间距离形成的区域可能混合建筑与背景，使区域汇总包含不相关内容；另一方面，外观相似的历史区域未必具有相同损毁等级，直接采用其标签可能引入错误证据。针对上述问题，本文提出一种建筑结构引导的区域表征与跨事件检索增强框架。首先，将预测建筑概率以连续相容项引入局部软归属，调节像素与区域的关联。其次，以建筑概率、相邻软归属相容变化量及归属熵作为条件，对光学—SAR 融合内容进行残差适配，并结合适配前特征统计和软几何形成区域表示。随后，在固定区域表示上，利用不同训练事件间的类别关系学习独立检索投影；该投影仅用于选择支持记录，读取器仍接收原始支持特征、训练软标签组成及元数据。增强区域特征经同一软归属回投，与保留的像素特征联合完成四类预测。实验围绕区域组织、内容条件化、支持排序及最终分类四个层面设置匹配对照，并分别评价总体、逐类别和逐事件表现。【待填：在协议锁定后补充主要结果、稳定性和计算代价；未获得结果前不写性能提升结论。】

关键词：建筑损毁评估；光学—SAR 融合；软区域；结构条件表征；跨事件检索

1 引言

灾后建筑损毁的位置与程度是应急评估的重要空间信息。灾前高分辨率光学影像能够描述建筑布局、形态和周边环境，灾后 SAR 则提供受光照与云层影响较小的观测。BRIGHT 以灾前光学与灾后 SAR 组合建立建筑损毁评测任务，为多灾害事件下的模型比较提供了统一基础[1]。与同模态变化检测不同，该任务需要在传感器成像差异和可能存在的配准残差下，利用异质观测判断建筑损毁等级。

现有像素模型通过多模态编码和融合输出密集类别预测。像素级判别保留空间细节，但局部判断与建筑结构之间可能不一致。可学习软区域提供了另一种信息组织方式：一个像素按不同权重关联邻近区域，区域特征

再用于像素判断[3,4,6]。然而，区域组织本身并不保证语义正确。跨越建筑与背景的区域可能稀释建筑证据，较大的区域也可能汇集不同建筑及不同损毁类别。区域边界更规整并不必然意味着损毁预测更准确。

外部训练案例提供另一种补充信息。检索增强分类利用训练特征及其标签关系辅助当前预测[10,11]，与当前图像内部的空间上下文具有不同的信息来源。但检索相似性与任务相关性并不等价：两处区域可以在外观、地表环境或 SAR 响应上接近，同时具有不同损毁等级。因此，既要检验邻居是否具有更相关的类别组成，也要检验模型是否从这些邻居中获得超过当前区域和额外模型容量的收益。

本文把问题分为三个相衔接的环节：哪些像素形成区域、区域内哪些内容需要条件化处理，以及哪些历史区域值得作为支持。建筑概率以软相容项影响区域归属；分区状态作为条件调节已融合特征；跨事件类别监督用于调整支持排序。当前像素路径始终保留，区域与支持信息作为联合判别的上下文。本文不预设三个环节各自都能提高性能，而通过独立对照和交互分析明确其作用。

本文研究以下三个方法设计及其验证问题：

1. **建筑概率约束的软区域组织。** 在外观与空间关联之外引入预测建筑概率，检验其是否在相同区域预算下减少无关混合，并改善后续损毁判断。
2. **分区状态条件的内容适配。** 利用建筑概率、软归属相容变化和归属熵调节融合内容，检验结构条件是否优于参数规模相近的普通内容适配。
3. **跨事件类别监督的支持排序。** 在固定区域内容及固定支持库上学习检索投影，分别检验邻居相关性与像素分类增量，并通过固定读取器仅替换支持 ID 控制读取器适应性。

上述三点是待实验支持的方法主张。软分区、注意力池化、交叉注意力及像素—区域联合分类均有已有研究基础，不单独列为创新。最终贡献表述以实验实际支持的范围为限。

2 相关工作

2.1 建筑损毁评估与多模态观测

xBD 推动了灾前与灾后光学建筑损毁研究[2]。BRIGHT 进一步提供灾前光学与灾后 SAR 组合及标准评估协议[1]。本文沿用既有任务、数据与像素前端，将研究重点放在融合特征之上的区域组织和支持利用，不把输入模态组合、数据集或基础融合网络作为新增贡献。跨模型比较必须核对输入、预训练、数据划分、标签映射、输出解码和指标定义。

2.2 软区域与对象先验

SSN 将局部像素—中心关联与区域更新构造成可微过程[3]，全卷积超像素方法直接预测局部关联[4]。SPAM 进一步研究对象掩膜先验与可学习超像素的结合[5]。因此，“使用超像素”或“引入对象先验”本身不能构

成充分的新颖性。本文研究的具体位置是：将模型预测的建筑概率作为连续相容项加入软归属，并分析其与内容适配的关系。预测概率不是测试真值，软区域也不等于建筑实例。

2.3 区域上下文与条件化表示

OCR 通过软对象区域组织上下文并增强像素表示[6]，条件化特征方法如 FiLM 说明外部条件可用于调节网络中间特征[7]。本文不把特征调制或区域回投当作新算子，而关注分区状态是否为融合内容提供有用条件。建筑概率、软归属变化和归属熵的作用需分别去除，并与有效容量相近的内容适配器比较。注意力图仅展示模型权重，不能单独证明模型关注了正确损毁线索。

2.4 类别监督与检索增强分类

跨图像像素对比学习利用标签关系组织分割特征[8]，监督对比学习显式约束同类与异类表示[9]。RAC 与 Tip-Adapter 等工作利用训练案例的特征及标签增强分类[10,11]。SRAC 与本文同属超像素检索增强的多模态损毁评估方向[12]，因此不能将“超像素加 Memory”作为区别于它的充分贡献。本文需要在建筑概率的作用位置、分区状态条件化及跨事件支持排序等具体机制上给出证据，并明确本文是否只是已有机制在该任务中的组合与验证。当前未取得 SRAC 可核对的全文及官方实现，不能断言其没有这些机制。

3 所提方法

3.1 任务、符号与信息边界

输入为配对的灾前光学影像与灾后 SAR 影像，输出为背景、完好、受损和毁坏四类像素预测。基础像素模型记为 A1，它提供光学结构描述、预测建筑概率 B 及光学—SAR 融合特征 F。本文中的“适配前特征”指进入新增结构适配器之前的 F，不等于原始 SAR 观测；如果基础前端已经使用软建筑调制，应在实现说明中保留这一事实。

软归属 q_{ik} 表示网格位置 i 对区域 k 的权重，且对每个位置满足 $\sum_k q_{ik}=1$。区域表示为 T_k。支持库记录包括训练区域的特征、软标签组成、几何和来源信息。预测建筑概率来自模型，验证和测试标签不参与分区、特征编码、支持选择及读取。

图 1 应区分四个时段：区域编码学习、Train 支持库构建、检索投影学习、Reader 与联合头学习。图中单独标出每阶段冻结和更新的模块，避免把分阶段训练画成所有模块端到端联合更新。

3.2 建筑概率约束的局部软归属

在结构特征网格上设置规则种子，每个位置只关联邻近候选中心。为延续初稿设计，采用种子步长 8、最多 9 个候选及 3 次关联更新作为主配置；这些是待锁定的实验设置，不表示已经完成验证。

记像素和中心的预测建筑概率为 B_i 与 $\acute{B}_k$，定义相容项：

$$\kappa_{ik}=B_i\acute{B}_k+\left(1-B_i\right)\left(1-\acute{B}_k\right).$$

归属打分综合描述子亲和、空间距离与建筑相容性：

$$s_{ik}=\beta\langle\widehat{W_q r_i},\widehat{W_k c_k}\rangle/\tau_q-\lambda_x\parallel x_i-\acute{x}_k\parallel_2^2+\lambda_B\log max\left(\kappa_{ik},\epsilon\right).$$

在有效局部候选中使用 Softmax 获得 q_{ik}，再按关联权重更新中心描述子、坐标和建筑概率。建筑概率进入该模块前停止梯度；标签不参与前向计算。对照实验关闭建筑相容项时只设置 $\lambda_B=0$，保持描述子、候选范围、种子预算、温度和训练协议一致。

该相容项鼓励建筑状态接近的位置具有更相容的关联，但不提供建筑实例 ID，也不强制区域连通。其效果应以实际混合度、有效区域数、边缘错误及最终预测共同判断。

3.3 分区状态条件的内容适配

对相邻位置的归属，应先按全局区域 ID 对齐；不能直接比较各位置局部候选数组中相同下标。沿用初稿的相容变化量：

$$b_i(Q)=\max_{j\in A(i)}\left(1-\sum_k q_{ik}q_{jk}\right),H_i(Q)=-\sum_k q_{ik}\log max\left(q_{ik},\epsilon\right)/\log 9.$$

其中 $A(i)$ 为四邻域。需要说明，$1-\langle q_i,q_j\rangle$ 不是严格的分布距离：即使两个分布相同，只要归属较分散，该值仍可能非零。因此本文称其为相容变化量，不把它直接称为真实建筑边界；$H(Q)$ 也不是经过校准的损毁预测不确定性。二者可能相关，其独立作用由条件消融决定。

以 $S_i=\left[B_i,b_i(Q),H_i(Q)\right)$ 构造条件嵌入，对内容进行残差适配：

$$\widetilde{F}_i=P_f\left(F_i\right)+\Lambda\odot MLP\left(\ln\left[P_f\left(F_i\right);P_s\left(S_i\right)\right)\right).$$

基础内容投影 P_f 在所有结构变体中保留。对照中的“无适配”仅去除残差适配，不能同时删除内容投影或改变输出维度。普通内容 Adapter 使用实际内容输入和匹配的瓶颈结构；把条件置零并保留闲置参数只适合条件删除，不足以替代有效容量对照。

区域表示由三条路径组成：注意力加权的适配内容 μ_k^{att}、适配前融合内容的加权均值与标准差 $\left[\mu_k^{raw};\sigma_k^{raw}\right)$，以及区域质量、软质心和空间扩展等软几何 g_k：

$$T_k=\ln\left[\phi\left(\mu_k^{att}\right)+\tanh(\alpha)\psi\left(\left[\mu_k^{raw};\sigma_k^{raw}\right)\right)+\gamma\left(g_k\right)\right).$$

所有池化按有效质量归一化，零质量区域进行显式屏蔽。统计旁路用于保留适配前的信息，不能据此声称恢复了区域压缩已经丢失的像素细节。

3.4 固定训练支持库与跨事件检索投影

在选定并冻结的区域编码快照上对训练图像确定性编码。每条支持记录定义为 $m_s=(ID_s,T_s,\pi_s,g_s,e_s,d_s,image_s)$，其中 π_s 为按同一软归属汇总的四类训练标签组成，e_s 和 d_s 为事件与灾害类型。无效标签从计数分母中排除。建库成员、抽样种子、来源图像和特征版本均需保存。

为控制来源，主配置可沿用“事件×主类别”的分组抽样，每组上限 64 条；四类包含背景。该上限属于支持协议，不意味着实际条目数必然均衡。正式报告还应给出有效标签质量、前景质量、来源多样性及排除查询事件后的候选数。若删除背景或改变纯度阈值，应另列支持筛选实验，不与主方法混合变更。

在固定 T_s 上学习投影 G，以 $v_s=G(T_s)/\|G(T_s)\|_2$ 为检索键。初稿采用恒等初始化的 128 维线性映射；投影学习时只更新 G。高纯度训练区域用于构造不同事件的同主类别正例和异类别负例。主配置的类别纯度阈值为四类分布中的 $max_c\pi_{sc}\geq 0.8$，它不等于前景比例阈值，也不等于前景内部纯度。

对有效锚点集合 U，使用跨事件监督对比目标：

$$L_{ret}=-\frac{1}{|U|}\sum_{a\in U}\frac{1}{|P(a)|}\sum_{p\in P(a)}\log\frac{\exp(v_a^T v_p/\tau_m)}{\sum_{s\in C(a)}\exp(v_a^T v_s/\tau_m)}.$$

缺少跨事件正例或负例的锚点不进入该损失，并报告其覆盖率。类别均衡抽样仅用于 Train 投影拟合，不按评测查询的真实类别挑选邻居。推理时统一排除同事件及同图像记录，选取 Top-8 支持。原始余弦与学习投影必须使用相同成员、标签、候选排除规则和 K。

投影只改变支持 ID。若实现额外把投影特征或相似度送入 Reader，应单独说明并设置对照，不能继续声称仅改变排序。

3.5 支持读取与像素联合预测

选中 ID 后，从原始支持库读取 T_s,π_s,m_s，而不是用投影后的向量替换内容。支持特征形成键，特征与软标签、元数据嵌入形成值：

$$K_s=T_s,V_s=T_s+\pi_s E_y+E_d(d_s)+E_e(e_s)+E_g(g_s).$$

Reader 以当前区域为查询，执行带残差的交叉注意力与前馈更新，得到 T_k'。不足 K 条支持时使用显式屏蔽及预定义的可学习槽位策略，并报告实际真实支持覆盖。可学习槽位不是新的历史案例，也不等于模型能够拒绝错误支持。

增强区域特征通过同一 Q 回投：

$$C_i=\sum_k q_{ik}T_k',\ z_i=W_pF_i+W_cC_i+b.$$

分类得分按固定方式上采样后生成四类概率。该路径是特征回投后联合分类，不等同于先汇总类别概率再回填。像素与区域线性项也可写成拼接特征后的线性分类，不单独作为第四项创新。初始化时将像素权重和偏置复制自 A1 分类器，并将上下文权重置零；只有特征输入、分辨率、插值和概率解码也与指定 A1 路径一致时，才应通过实际核验确认初始预测一致。该初始化不保证后续训练不下降。

3.6 分阶段学习

首先确定 A1 快照及数据协议。冻结其参数和运行状态，训练区域组织、内容适配、嵌入和辅助区域读出。分割目标使用负对数似然与 Lovász-Softmax[13]，权重及所有变体保持一致。随后固定区域编码建立 Train 支持库，再拟合并冻结检索投影。最后固定前端、库和投影，仅学习 Reader 与联合头。

结构变体改变了区域成员和表示，因此其完整系统比较应为每个编码版本重新建立自己的支持库；纯检索排序实验则必须固定同一个编码版本和同一库。训练步数、选型规则及种子在实验前记录，不能将中途快照写成预定训练预算已全部完成。

4 实验设计与结果报告

4.1 数据划分与评价

采用 BRIGHT 标准机器学习划分，训练、验证和测试影像数分别为 2918、450 和 878：Train 用于参数学习和支持库，Val 用于有限选型，Test 用于协议固定后的结果报告。标准划分的图像互不重叠，不等于事件互不重叠。推理时排除同事件支持只约束支持来源；若主干训练中见过该事件，不能据此声称未见事件泛化。严格留事件评价需从 A1 学习、区域编码、投影、支持库及选型中全部排除目标事件，并对事件嵌入使用未知标记或移除该输入。

主指标同时报告四类 mIoU 与前景三类 mIoU，并列四个类别 IoU。全局指标由累计混淆矩阵计算；事件宏平均在每个事件内先计算，再等权平均，二者不能互换。分类 F1 按官方实现计算；独立建筑定位 F1 需要相应定位输出，不能用损毁分类混淆矩阵替代独立定位头。

所有主要对照使用相同划分、预训练、输入、解码、预算和检查点选择规则。主结论使用至少 3 个预先指定种子，报告均值、标准差和配对差值。按事件重采样的区间用于描述事件变异，不把数亿像素作为独立样本进行显著性检验。

4.2 总体比较

表 1 报告基础 A1、相同预算的像素读出、当前区域读出、参数化空支持、余弦 Memory 和学习排序 Memory。公开方法另列来源及协议，优先提供可复现的同设置重训结果。若公开数值来自不同设置，应明确分组，不与本文小幅差值作直接因果归因。

【待填：完整方法的全局及逐类结果、种子变化、与匹配对照的差值。只有真实结果支持时才写“改善”“优于”或“稳定”。】

4.3 区域组织与内容适配

表 2 使用建筑概率是否进入 Q 与结构残差适配是否开启的二因素实验。各组冻结同一 A1，关闭真实历史支持，使用相同区域—像素读出。表 3 增加普通内容 Adapter 及去除 B、b(Q)、H(Q)的对照，避免把增大容量或重复使用建筑概率解释为分区状态收益。

结构评价除分割指标外，报告有效区域数、区域质量分布及面积加权的建筑—背景混合度。令 $f_k=\pi_{k1}+\pi_{k2}+\pi_{k3}$，可报告 $4f_k(1-f_k)$ 的质量加权平均；该量反映前景与背景混合，不能检测不同前景损毁类别之间的混合。因此同时报告前景类别组成及预定义边界带内的错误率。改变 Q 也改变了池化、几何、条件量和回投，二因素差值是该结构干预的总体作用，不能只归因于边界更准确。

【待填：二因素主效应、交互项、条件消融和区域诊断。若只有联用有效，应将其表述为相互依赖的结构编码设计。】

4.4 支持信息与排序质量

表 4 比较当前区域直接回投、可学习空支持、真实余弦支持与学习排序支持。真实支持相对空支持的差值用于检验案例信息增量；空支持仍可能学习全局先验，不能称为纯当前区域。两个分别训练的 Reader 之间的差值是完整配置比较，不能单独证明纯排序作用。

为隔离排序，另以固定比例混合余弦邻居和学习邻居训练共同 Reader；评价时冻结该 Reader、联合头及其他权重，仅替换支持 ID。若不使用混合训练，则执行“Reader 训练邻居来源×评价邻居来源”的完整二乘二交叉替换。该对照连同检索相关度共同检验第三项设计。

检索评价对高纯度查询报告按类别及事件宏平均的 Precision@K；对混合查询报告软标签组成相关度，并分别展示背景、完好、受损和毁坏。有效 K 邻居覆盖率描述支持是否充足，不能替代语义相关性。对比普通监督与跨事件监督时，前者仅放宽事件限制，仍排除锚点自身及同图像记录；两者匹配有效采样规模，并在评价时统一排除同事件。评测标签只参与事后评分，不能影响支持选择。

【待填：邻居质量变化、固定 Reader 下的分类差值及其一致性。若只改善邻居指标，结论限定为支持选择改善。】

4.5 Reader 内容、事件表现与失败案例

固定成员 ID，删除标签或元数据并重新训练 Reader，用于检验其增量价值；推理时打乱标签或改用随机合格支持，用于检验已训练模型对证据的依赖与脆弱性。两类操作分别报告，不能把推理破坏造成的下降直接当作重新训练后的消融收益。

图 4—图 7 分别提供区域机制、实际支持案例、固定 Reader 预测差异和逐事件差值。所有模型使用同一窗口、分辨率和颜色图例；至少包含改善、持平与退化案例。A1 前端预测仅作为基础模型案例，不替代完整方法及 Memory 对照。若主张建筑实例一致性，还需真实实例多边形或 ID，报告实例内预测一致性与实例正确性；仅有语义掩膜时，连通块只能作为代理。

【待填：逐事件分布、受损/毁坏救回与误改、典型失败，以及哪些结论不成立。】

4.6 计算代价

分别报告 A1、区域编码、检索与 Reader 的新增参数量、训练时间、单图推理延迟、峰值显存及库容量。区分一次性建库/投影训练成本和在线推理成本；在固定硬件、线程、精度与批大小下测量。K、支持库规模及前景筛选阈值等敏感性实验放在核心机制证实之后，不同时改动多个因素。

5 讨论与结论

本文围绕区域成员、区域内容与历史支持构建光学—SAR 建筑损毁评估框架。建筑概率约束软归属，分区状态条件化融合内容，跨事件类别关系调整支持选择，增强区域特征与保留的像素路径联合预测。对应实验分别检验结构、检索及最终分类，避免将更规整的区域、更相似的邻居或额外模型容量直接解释为任务收益。

【待填：只总结已完成、可追溯且稳定的实验结论；明确不获益的模块与失败条件。】

方法存在若干边界。预测建筑概率可能出错，结构适配仍受基础特征限制；外部案例提供训练经验而非当前场景的新观测；跨事件支持排除不保证域不变或未见事件泛化；超像素不自动具备建筑实例身份。若关键消融不支持某项设计，应缩小贡献表述或简化模型，而不是继续以预设有效性解释结果。

参考文献与核验入口

下列为与设计直接相关的文献。完整题名、可访问入口及本轮核验范围见《实验与配图规划》的文献表；SRAC 仅按现有目录/新闻证据讨论，不引用其未核实实现细节。

[1] BRIGHT: a globally distributed multimodal building damage assessment dataset with very-high-resolution for all-weather disaster response. Earth System Science Data, 2025.

[2] Creating xBD: A Dataset for Assessing Building Damage from Satellite Imagery. CVPR Workshops, 2019.

[3] Superpixel Sampling Networks. ECCV, 2018.

[4] Superpixel Segmentation with Fully Convolutional Networks. CVPR, 2020.

[5] Superpixel Anything: A general object-based framework for accurate yet regular superpixel segmentation. BMVC, 2025.

[6] Object-Contextual Representations for Semantic Segmentation. ECCV, 2020.

[7] FiLM: Visual Reasoning with a General Conditioning Layer. AAAI, 2018.

[8] Exploring Cross-Image Pixel Contrast for Semantic Segmentation. ICCV, 2021.

[9] Supervised Contrastive Learning. NeurIPS, 2020.

[10] Retrieval Augmented Classification for Long-Tail Visual Recognition. CVPR, 2022.

[11] Tip-Adapter: Training-Free Adaption of CLIP for Few-Shot Classification. ECCV, 2022.

[12] SRAC: Superpixel Retrieval-Augmented Classification for Multi-Modal Disaster Building Damage Assessment. IGARSS 2026，现有证据限目录/新闻及用户提供的方法图。

[13] The Lovász-Softmax Loss: A Tractable Surrogate for the Optimization of the Intersection-Over-Union Measure in Neural Networks. CVPR, 2018.