面向光学–SAR 建筑损毁评估的结构条件区域编码与跨事件检索

摘要—灾前光学与灾后合成孔径雷达（SAR）影像为建筑损毁评估提供互补观测，但区域混合与外观相似性限制了结构组织和历史案例使用。本文构建结构条件区域编码与跨事件监督检索相结合的评估框架：以预测建筑概率约束局部软归属，以分区状态调节融合内容，在固定区域表示上学习跨事件支持排序，并通过原始案例读取和区域回投完成像素联合分类。实验围绕总体性能、区域条件和历史支持组织验证。已确认的 MPF 像素前端在 BRIGHT 标准 Test 上的四类 mIoU 为 68.54%，前景三类 mIoU 由报告分项计算约为 59.06%；该成绩作为完整框架的参照，不代表新增检索模块的效果。完整新配置及控制实验成绩待统一评价，本文据现有记录分析类别取舍、局部错误及后续验证条件。

关键词：建筑损毁评估；光学–SAR 遥感；建筑软分区；结构条件特征适配；跨事件区域检索

I. 引言

建筑损毁的位置和程度为灾后救援与资源分配提供空间依据。xBD 推动了灾前、灾后光学影像中的建筑定位和损毁分级研究[1]。灾后光学获取受云雾、光照和重访时机限制，灾前光学与灾后 SAR 构成可用的互补观测；BRIGHT 为这一组合提供了多事件标准评测数据[2]。本文以背景、完好、受损、毁坏四类密集预测为目标，不将既有数据集或跨模态输入组合本身作为贡献。

已有方法从对象变化、双任务表征和状态空间建模等角度组织损毁证据。ChangeOS 将建筑对象语义与损毁状态联系起来[3]，双任务孪生 Transformer 联合建模定位与等级[4]，ChangeMamba 探索时空状态空间表征[5]。同时，迁移研究表明熟悉划分上的性能不能代替对新灾害分布的验证[6,7]。因此，本研究同时区分区域组织、区域内容和外部支持，分别检验其作用，而不把整条路径的增益归于某一个组件。

第一个问题出现在区域归属阶段。灾前光学特征能够描述局部形态，空间距离能够限制区域范围，但仅凭二者组织的区域可能跨越建筑与背景。预测建筑概率包含更直接的结构线索，同时也可能出现误检或漏检。因而本文让建筑概率以连续相容项进入局部归属计算，而不将其阈值化为不可调整的硬边界。第二个问题出现在区域内容阶段。即使成员由软归属确定，同一区域内的边缘位置和归属分散位置仍可能具有不同的判别价值；仅改变 Q 而不改变融合特征，不能检验分区状态是否有助于区域表示。第三个问题出现在历史支持阶段：区域特征的外观近邻未必是损毁等级相关的邻居，特别是在不同事件之间。

围绕这三个问题，本文按“区域成员—区域内容—历史支持”的顺序构建模型。灾前光学描述子和预测建筑概率共同生成局部软归属 Q；建筑概率、相邻位置的软归属差异及归属熵再作为条件，对光学–SAR 融合特征作残差适配。区域嵌入汇集适配内容、适配前的特征统计和软几何。在固定区域表示上，利用训练区域的跨事件同类与异类关系学习检索投影；投影只改变邻居 ID，支持读取仍使用原始区域特征、训练标签组成及元数据。最后，增强区域特征经同一 Q 回投，与保留的像素特征共同分类。区域回投及像素联合头承担读出功能，不单列为方法创新。

围绕三个设计环节，本文构建由总体比较、区域组织与内容适配消融、历史支持与排序对照、检索质量、事件表现和配对案例组成的验证链。区域组织指标与最终分割指标分别报告，检索相关度与分类收益分别分析。所有结果表保留原始计数的可追溯来源，避免将递进配置的差值直接解释为单个模块的独立作用。

本文研究三项相衔接的方法设计：（1）建筑概率约束的局部软分区，在外观亲和与空间约束之外调节像素—区域归属；（2）分区状态条件的内容适配，以建筑概率、软归属相容变化和归属熵调整融合内容，同时保留适配前统计路径；（3）跨事件类别监督的支持排序，在固定区域内容上学习检索投影，并保持原始支持读取路径。上述环节的独立作用与交互由控制实验评价，不预设每一环节均具有正向增益。第 II 节介绍相关工作，第 III 节给出方法，第 IV 节按统一协议组织验证，第 V 节总结方法及适用边界。

II. 相关工作

A. 建筑损毁评估与光学–SAR 融合

像素分割研究形成了从 FCN、U-Net 到空洞卷积编码–解码器的技术路线[8,9,10]，残差网络、Swin 和 SegFormer 进一步丰富了视觉骨干与多尺度表示[11,12,13]。多源变化检测的 SiamCRNN 为双时相关系建模提供了相关基础[14]；建筑任务中的 MS4D-Net 研究少标注条件下的多任务一致性，OCD-BDA 研究对象级震后变化[15,16]。这些研究输入、监督与输出层级不同，本文只在 BRIGHT 统一协议下比较适配版本，不能直接拼接不同任务的成绩。

BRIGHT 以灾前光学与灾后 SAR 建立多灾种损毁评测[2]。本文沿用既有多模态像素前端（MPF），重点考察像素预测之后的区域成员、区域内容和历史支持。已有建筑信息不因关闭新增相容项而消失，因此后续"B→Q 关闭"仅表示移除本文新增的归属项。跨事件支持选择与真正未见事件泛化也分开表述；后一问题需要专门划分和实验[6,7]。

B. 建筑先验与可学习软分区

SLIC 在颜色与空间位置的联合空间中构造超像素[17]；SSN 将区域关联更新改为可微过程[18]；全卷积超像素方法直接预测局部关联[19]。这些工作已经建立软关联、区域汇总与回投的基础，本文不将"采用超像素"本身作为创新。

对象先验指导区域组织已有研究。Superpixel Anything 将对象信息用于超像素生成[20]，因而建筑或对象先验本身不能构成首创性主张。本文检验的是预测建筑概率进入局部连续相容项的具体方式，并同时考察区域混合率、有效区域数量和最终分类，避免将视觉上规整的分区等同于损毁识别改善。

本文在这一路径中加入预测建筑概率的软相容项，研究结构线索能否改善损毁任务中的区域归属。相容性来自模型预测，而非测试标签或建筑实例轮廓；它影响归属权重 Q，但不能保证每个区域都对应单栋建筑。因此分区质量需结合混合区域和最终损毁分类评价，不能只展示更整齐的边界。

C. 区域内容表征与像素上下文

区域与上下文表征已有多种路径。OCR 聚合对象上下文，PSPNet 汇聚多尺度区域，DANet 和 Non-local 模块扩大特征关系的作用范围[21,22,23,24]；SENet 与二阶池化分别研究通道重标定和统计表征[25,26]。WANet 针对遥感沟渠提取研究小结构和背景干扰[27]，其任务与建筑损毁不同，本文仅参考其分层结果分析方式，不将其数值作为建筑任务基线。由此，注意力、统计汇总和回投是基础组件，本文的结构侧问题是分区状态如何具体影响融合内容。

本文关注软分区形成之后的信息使用方式。建筑概率反映预测的结构状态，相邻软归属差异 b(Q)和归属熵 H(Q)分别描述局部归属变化与分散程度。三者在融合特征层调节区域内容，并与未经该适配的统计旁路结合。这里的 b(Q)不等于真实建筑边界，H(Q)也不是校准过的损毁预测不确定性。与普通内容适配器和去除条件量的对照用于判断这些分区信号是否真正提供额外信息。

条件化中间特征已有 FiLM 等方法[28]。本文的结构条件残差适配不等同于 FiLM：输入是建筑概率、软归属相容变化和归属熵。是否优于普通内容处理，需在固定 Q、相近活跃参数和训练预算下检验，并逐项去除这些条件；不能仅凭额外 MLP 带来的结果主张结构条件有效。

D. 外部支持与跨事件检索

跨图像像素对比学习和原型分割利用标签关系组织密集特征[29,30]；Prototypical Networks 及 FEAT 研究支持样本的类别表示与适配[31,32]，Tip-Adapter 将训练特征与标签构成预测缓存[33]。这些研究支持将"寻找何种支持"和"如何读取内容"作为两个问题，但其分类任务及训练设置不能直接替代本任务的控制实验。

还需区分训练字典与推理支持库。Cross-Batch Memory、MoCo 和 DenseCL 分别在度量学习或表征预训练中使用跨批特征与密集对比[34,35,36]，不等于部署时读取带损毁标注的历史案例。本文使用 Train 区域的跨事件类别关系拟合投影，其监督与 SupCon 的类别约束有关[37]；推理仅按投影返回支持 ID，再由注意力式读取器使用原始记录[38]。同类邻居是否更多、最终分类是否提高、是否真正依赖支持标签，需分别验证。

本文不把“超像素加 Memory”作为充分的新颖性依据，而将方法落在建筑连续相容、分区状态内容适配与跨事件支持排序三项可检验设计上。相关任务、区域上下文、原型与缓存研究共同提示：额外上下文、读取容量或类别先验本身都可能改变成绩。因此，必须匹配当前图像上下文与参数化支持，并对固定读取器进行邻居 ID 替换，才能进一步讨论历史案例的增量。

III. 所提方法

A. 任务定义与总体框架

输入为空间配对的灾前光学影像和灾后 SAR 影像，输出为背景、完好、受损和毁坏四类像素预测。建筑概率由模型从光学观测中估计；像素级融合特征结合两种模态提供内容。区域是连接像素与支持检索的中间计算单元，允许一个位置按权重关联多个局部中心，不提供建筑实例身份，也不保证一个区域只包含一栋建筑。

记当前图像的软归属为 Q、区域特征为 T，训练支持库为 M。模型首先生成当前区域表示，再从 M 选择支持并获得增强区域特征，最后回投为空间上下文，与原像素特征共同分类。训练标签用于损毁监督、支持区域类别组成和检索度量学习；验证或测试图像的真实标签不参与前向分区、支持选择和分类读取。

设配准后的输入为 X^{opt} 和 X^{sar}，预测目标为四类别像素图。整体框架包含建筑概率约束的局部软分区、分区状态条件的区域特征适配、跨事件类别监督的支持排序，以及支持读取与像素联合判别，如图 1 所示。前三项分别决定区域成员、区域内容与历史支持，读出路径将区域证据用于密集预测。

本文将提供建筑概率、融合内容和像素预测的基础网络统一称为多模态像素前端（Multimodal Pixel Frontend，MPF）。直接使用其既有分类器时写为 MPF；冻结同一前端、按匹配预算只训练像素头的对照写为像素头适配（Pixel-Head Adaptation）。完整检索框架写为 Ours，内部配置按实际计算路径命名，不沿用 A1、J0 等内部编号。

基础像素模型沿用项目中的双分支编码与多尺度融合，骨干结构参考 Swin Transformer[12]，建筑定位与等级预测采用双任务设置[4]。预训练像素前端提供多尺度光学特征、预测建筑概率 B 及光学–SAR 融合特征 F。其中，F 已经过前端的软建筑区域调制；后文所称“未适配特征”仅指进入本文结构适配器之前的融合特征，而非原始 SAR 信号。光学特征经嵌套解码器得到结构描述子 R，用于生成局部软区域归属 Q。在此基础上，区域编码器将结构条件适配后的内容、未适配内容统计和软几何信息汇总为区域表示 T。

对于每个查询区域，检索器从仅含训练样本的支持库中选择不同事件和图像的邻居。支持读取器结合未投影的支持特征、训练标签组成与元数据，生成增强区域表示 T'。随后通过同一软归属 Q 将其分配回像素网格，并与保留的 F 联合分类。由此，建筑结构用于组织当前区域，跨事件监督用于调整支持选择，而像素路径保留未经过区域池化的分类输入。

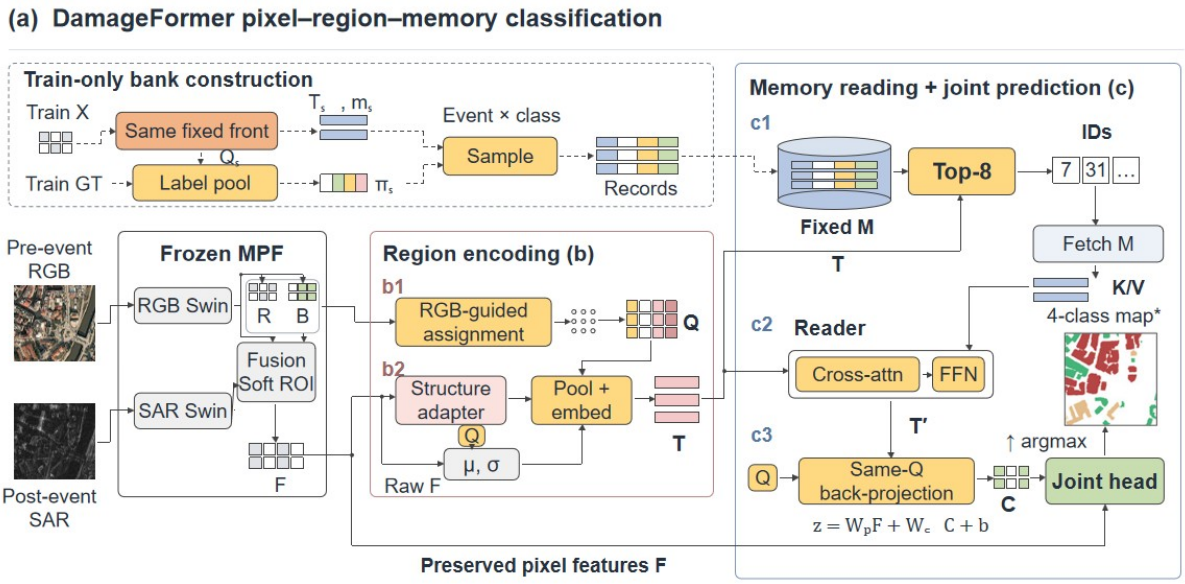


图 1　总体框架。离线支持仅来自 Train；查询端由 MPF 提供建筑概率 B、结构描述 R 与融合内容 F，Q 组织区域，检索返回 ID 并读取原始支持，增强区域经当前图像自己的 Q 回投，与 F 共同分类。

B. 建筑概率约束的局部软分区

直接按规则网格汇总特征不能利用影像结构，而完全依赖局部外观相似性也未显式利用建筑预测。本文在局部描述子亲和度与坐标约束之外，将预测建筑概率作为软兼容项，参与像素到区域中心的归属计算。该设计使建筑预测影响分区，同时避免以固定阈值将建筑和背景硬拆为两组区域。

局部迭代沿用可微超像素的关联更新思路[18]。在特征网格上以步长 8 均匀设置种子。对位置 i，候选集合 $N(i)$ 包含其所在种子格及周围相邻格，至多含 9 个候选中心。结构描述子经层归一化得到 r_i；查询和中心键分别由可学习线性映射及单位长度归一化获得。对第 t 轮归属，以前一轮权重汇总单位长度归一化后的描述子、中心坐标和中心建筑概率，分别记为 $c_k^{(t)}$、$\bar{x}_k^{(t)}$ 和 $\bar{B}_k^{(t)}$。建筑软兼容度定义为

$$\kappa_{ik}^{(t)} = B_i \bar{B}_k^{(t)} + (1 - B_i)(1 - \bar{B}_k^{(t)}). \tag{1}$$

归属打分同时考虑描述子亲和度、局部距离和建筑软兼容度：

$$s_{ik}^{(t)} = \frac{\beta \langle \hat{W}_q r_i, \hat{W}_k \hat{c}_k^{(t)} \rangle}{\tau_q} - \lambda_x \| x_i - \bar{x}_k^{(t)} \|_2^2 + \lambda_B \log \kappa_{ik}^{(t)}. \tag{2}$$

其中，带帽符号表示单位长度归一化，β 为可学习正缩放系数，τ_q 为温度，坐标按种子步长归一化。默认温度为 0.2，空间权重为 0.1，建筑兼容权重为 0.5；中心建筑概率截断至 0.0001 与 0.9999 之间，兼容度下界为 0.0001。无效或无质量的中心不参与归一化。局部归属为

$$q_{ik}^{(t)} = \frac{\exp s_{ik}^{(t)}}{\sum_{l \in N^{valid}(i)} \exp s_{il}^{(t)}}$$

$$\sum_k q_{ik}^{(t)} = 1. \tag{3}$$

初始归属将每个位置分配给其所在种子格，随后迭代更新中心和归属，默认进行 3 轮。建筑概率来自像素前端的预测，输入分区模块和结构适配器前均停止梯度；训练标签不参与单次前向分区计算。最终 Q 是局部软关联，而非建筑实例标注，不要求一个区域严格对应一栋建筑。

C. 分区状态条件的区域特征适配

软归属给出了区域组织方式，但仅在区域内平均特征仍未显式利用局部建筑状态及归属分散程度。本文构造结构条件向量，对融合内容进行特征级残差适配，如图 2 所示。结构条件由建筑概率、软分区差异及归属熵组成。

将稀疏局部归属理解为全局区域编号上的分布。对位置 i 及其四邻域内位置 j，软分区差异定义为

$$b_i(Q)=max_{j\in A(i)}\left(1-\sum_k q_{ik}q_{jk}\right)$$
$$H_i(Q)=-\frac{\sum_k q_{ik}\log q_{ik}}{\log 9}. \tag{4}$$

$b_i(Q)$ 描述相邻位置归属的一致程度，不等同于真实建筑边界；$H_i(Q)$ 描述归属分散度，不作为经校准的预测不确定性。三种结构量缩放至融合特征网格后，由线性投影得到结构嵌入。结构适配为

需要注意，式（4）的 $1-\langle q_i,q_j\rangle$ 不是严格的分布距离：相邻归属分布相同但较分散时，该量仍可能非零。因此本文将其称为软归属相容变化量，不将其视为真实建筑边界；其与归属熵可能相关，独立作用需由固定 Q 的条件消融检验。相邻位置的局部候选必须先按全局区域 ID 对齐后再计算。

$$\tilde{F}_i=P_f(F_i)+\Lambda\odot MLP\left(\ln[P_f(F_i);P_s(B_i,b_i,H_i)]\right). \tag{5}$$

P_f 将 256 维融合内容投影至 128 维，P_s 将三维结构条件投影至 128 维。拼接后的 256 维向量经层归一化和两层感知机生成 128 维增量，Λ 是逐通道可学习缩放量，初值为 10^{-3}。这一初始化减小初始特征扰动，并不构成训练后的无损或性能不下降保证。

区域表示结合适配内容、未适配内容统计和区域几何。首先，通过点卷积与 Sigmoid 生成位置权重 a_i，再计算区域的注意力加权适配内容。该量在图 2 与式（6）中均记作μ_k：

$$a_i=\sigma(w_a^{\top}\tilde{F}_i+b_a)$$
$$\mu_k=\frac{\sum_i q_{ik}a_i\tilde{F}_i}{max\left(\sum_i q_{ik}a_i,\epsilon\right)}. \tag{6}$$

图 2 统计旁路中的均值在下文记作$\overline{F}_k$，以区别于注意力加权的μ_k。式（6）、（7）中的数值稳定下界为 10^{-6}。另一方面，以 $m_k=\sum_i q_{ik}$ 为区域质量，从未经过结构适配的 F 计算原特征均值$\overline{F}_k$和标准差：

$$\overline{F}_k=\frac{\sum_i q_{ik}F_i}{max(m_k,\epsilon)}$$
$$\sigma_k=\sqrt{max\left(\frac{\sum_i q_{ik}F_i^{\odot 2}}{max(m_k,\epsilon)}-\overline{F}_k^{\odot 2},0\right)+\epsilon}. \tag{7}$$

几何向量 g_k 包含归一化区域质量、二维软质心及两个坐标轴上的软扩展度，共 5 维。这里的几何由 Q 与归一化坐标计算，不使用真实建筑轮廓。最终区域表示为

$$T_k=\ln\left(\phi(\mu_k)+\tanh(\alpha)\psi([\overline{F}_k;\sigma_k])+\gamma(g_k)\right). \tag{8}$$

ϕ、ψ 和 γ 为相应投影，输出维度均为 128；α 为可学习标量，初值为 0.1。质量不足的区域被标记为无效。主配置不额外使用全局区域自注意力。注意力池化、统计汇总和几何编码构成区域表征的基础组件，本文的结构侧方法重点是建筑软先验约束与分区信息驱动的特征适配。

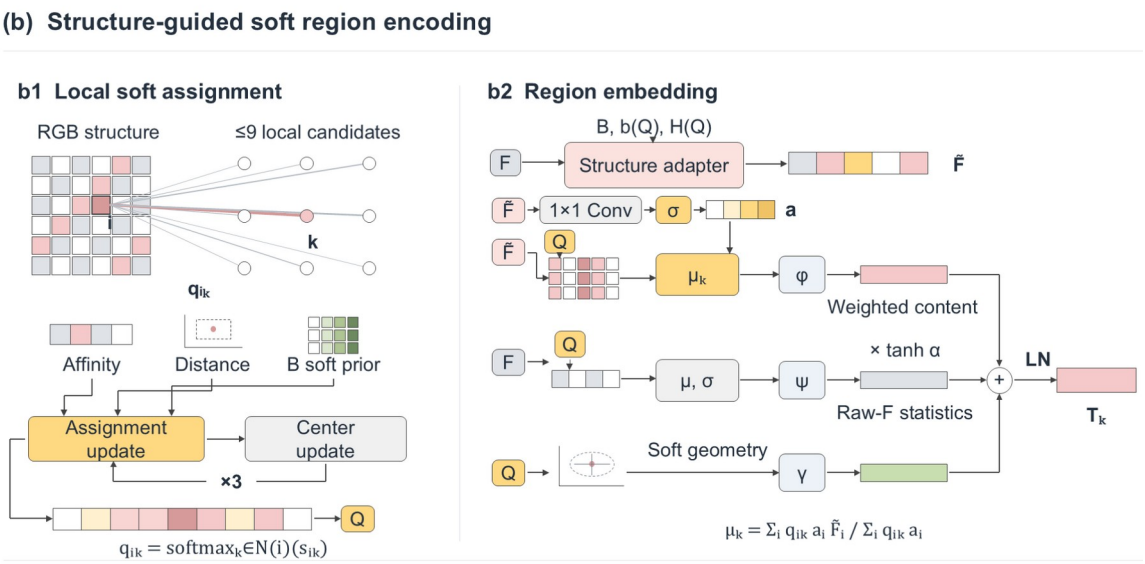


图 2　建筑相容分区与结构条件区域编码。建筑概率进入局部相容项；B、b(Q)、H(Q)调节融合内容，并结合适配前统计和软几何形成区域表示。b(Q)不是 GT 建筑边界，H(Q)不是损毁概率的不确定性。

D. 跨事件目标类别监督的区域检索

1) 训练区域支持库

固定训练后的区域前端，对训练影像执行确定性的全图编码。每条候选记录包含区域表示 T_s、训练标签组成 π_s、区域几何、事件编号、灾害类型及图像编号。训练标签首先转换为四类别指示图，忽略无效标签，再通过面积缩放得到特征网格上的类别占比 y_{ic}。区域类别分布为

$$\pi_{kc} = \frac{\sum_i q_{ik} y_{ic}}{max\left(\sum_i q_{ik} \sum_{c'} y_{ic'}, 10^{-8}\right)}. \tag{9}$$

支持库按“事件×主类别”分组，以随机优先级抽样保留每组至多 64 个区域。主类别涵盖背景、完好、受损和毁坏；其中后三类用于建筑损毁等级分析。该分组控制支持来源，并不在查询时按真实类别选择邻居。主设置建库时保留具有有效标签质量的混合区域，因此后续使用其完整类别分布，而非只使用一个硬标签。验证和测试影像及其标签均不进入支持库。

2) 跨事件类别监督的检索投影

检索相关性由区域表示的相似性决定，而分类所需要的支持应与背景、完好、受损和毁坏四类目标标签相关。为检验二者能否更一致，本文在固定区域表示上学习一个独立检索投影。该投影只决定支持记录的排序；读取阶段使用原始支持表示及其记录内容。

设 $W_m \in \mathbb{R}^{128\times128}$ 为无偏置、恒等初始化的线性映射，检索键定义为

$$v_s = \frac{W_m T_s}{max\left(\|W_m T_s\|_2, 10^{-12}\right)}. \tag{10}$$

度量拟合使用支持库中主类别占比不低于 0.8 的区域。对锚点 a，候选集合 $C(a)$ 仅含不同事件且不同图像的合格区域；正样本集合 $P(a) \subset C(a)$ 进一步要求主类别相同，其余候选为负样本。依据监督对比学习的类别约束[37]，采用跨事件候选上的目标：

$$\mathcal{L}_{ret} = -\frac{1}{|U|}\sum_{a\in U}\frac{1}{|P(a)|}\sum_{p\in P(a)}\log\frac{\exp\left(v_a^{\top} v_p/\tau_m\right)}{\sum_{s\in C(a)}\exp\left(v_a^{\top} v_s/\tau_m\right)}. \tag{11}$$

U 为同时具有跨事件正、负样本的锚点集合。锚点按可用类别均衡抽样；缺少有效配对的样本不通过同事件配对补足。主配置要求四类均有跨事件覆盖，温度 τ_m 为 0.1。拟合期间区域表示及支持库固定，梯度仅更新 W_m。高纯度条件用于度量拟合，不等于推理支持库只保留高纯度区域。

对于查询区域 k，在排除同事件及同图像记录后，使用 $v_k^{\top} v_s$ 选取 Top-8 支持。查询标签不参与检索。余弦检索对照使用原始 T 的单位长度归一化，其余支持库成员及读取结构保持一致。跨事件监督是对邻居选择的约束，不据此直接假定已经得到事件不变表示。

E. 支持读取与像素联合判别

对检索得到的支持集合 S_k，读取器以区域内容作为键，将标签组成和元数据嵌入加入值向量：

$$K_s = T_s$$
$$V_s = T_s + \pi_s E_y + E_d(d_s) + E_e(e_s) + E_g(g_s). \tag{12}$$

其中，E_y 为四类标签嵌入表，E_d、E_e 与 E_g 分别编码支持的灾害类型、事件及几何；$\pi_s E_y$ 保留混合区域的类别组成。查询、键和值分别归一化后进入四头交叉注意力，随后通过残差与前馈网络更新查询区域：

$$U_k = T_k + MHA\left(\ln_q T_k, \ln_k K_{S_k}, \ln_v V_{S_k}\right)$$
$$T_k^{'} = U_k + FFN\left(\ln U_k\right). \tag{13}$$

不足 8 个有效邻居时，对缺失位置使用可学习支持槽替代；无真实支持的对照模型使用相同数量的可学习槽。此机制保证读取输入定义完整，不用于判断已有邻居是否正确。事件嵌入用于支持内容编码，与检索时排除同事件是两个不同操作，其作用需通过元数据消融检验。

增强区域表示通过生成区域时的同一 Q 映射至特征网格，得到区域上下文 C。随后与保留的像素特征共同产生分类得分：

$$C_i = \sum_k q_{ik} T_k^{'}$$
$$z_i = W_p F_i + W_c C_i + b. \tag{14}$$

联合得分经双线性插值恢复至输入分辨率，再作类别 Softmax。这里回投的是区域特征，最终概率在联合分类后产生。Q 回投并非区域池化的逆变换；保留像素路径的目的，是让分类器仍可使用未经过区域压缩的输入，而非宣称已经恢复丢失信息。式（14）在代数上等价于拼接特征后的线性分类，其在本文中承担整体读出功能。

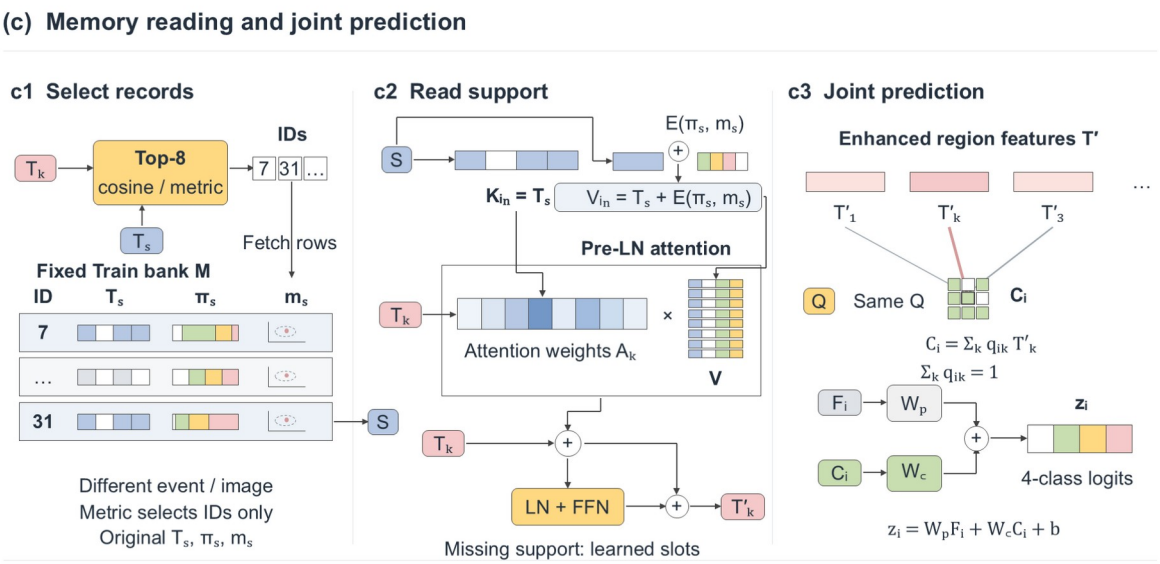


图 3　跨事件支持选择与读取。投影改变支持 ID；Reader 读取未投影特征、Train 标签组成与元数据。区域上下文与独立保留的像素路径共同进入分类头，不同图像分别计算各自的 Q。

F. 分阶段训练与目标函数

训练分为区域前端学习、固定 Train 支持库构建、检索投影拟合及联合读出学习四步。建筑相容项与结构适配器在区域前端中学习，检索投影在区域表示固定后拟合。联合阶段冻结像素前端、区域编码、支持库及投影，仅更新 Reader 与联合头。最终预算、种子、权重、代码与评估版本记录于配套数据核对表，不以历史中途快照替代正式配置。

首先，冻结预训练像素前端的参数与运行状态，仅训练结构描述解码器、软分区模块、结构适配器、区域嵌入及辅助区域分类器。辅助分类器将 T_k 转为四类概率，通过 Q 分配回像素网格并恢复至标签分辨率，用于前端监督。此处的区域概率投影只服务于前端训练及区域对照，完整模型的最终读出采用式（14）的特征回投。

对有效标签像素集合 Ω，分割训练目标由平均负对数似然与 Lovász-Softmax 组成，后者用于构造分割交并比的优化代理[39]：

$$\mathcal{L}_{seg} = -\frac{1}{|\Omega|}\sum_{i \in \Omega} \log max\left(p_{i,y_i}, 10^{-8}\right) + \mathcal{L}_{Lovasz}\left(p, y\right). \tag{15}$$

两项损失等权使用，无效标签忽略；主配置不附加类别重加权、独立边界损失或归属熵最小化损失。前端学习完成或选定明确记录训练步数的快照后，固定前端并构建训练支持库。随后按式（11）拟合检索投影，拟合完成后将其冻结。

最后，固定像素前端、区域编码、支持库及检索投影，仅训练支持读取器和联合分类头，仍使用式（15）。像素权重与偏置复制预训练分类器，上下文权重零初始化；在输入特征、运行状态、插值与解码一致的前提下，实际核验初始预测是否匹配指定像素路径。训练后像素权重和上下文权重均可更新，初始化不保证最终精度单调提高。

IV. 实验与结果分析

A. 数据、评价指标与比较协议

实验采用 BRIGHT 标准机器学习划分，Train、Val、Test 分别为 2918、450 和 878 幅影像[2]。Train 用于拟合网络、构建支持库和学习排序；Val 用于选型；配置锁定后统一评价 Test。此前探索性 Test 访问在实验记录中保留，不重新称为未访问的盲测。图 4 展示事件与模态范围。



图 4　BRIGHT 事件分布与影像示例。数据覆盖多灾种场景；标准名单决定实际划分。该图说明数据来源和评价范围，不代表本文创建了新数据集。数据来源：BRIGHT[2]。

由有效像素累计 4×4 混淆矩阵，行是真值、列是预测；背景、完好、受损、毁坏按固定类序计算 IoU。四类 mIoU 平均全部四类；前景 mIoU 只平均后三类。OA 不能代替少数损毁类别指标。定位 F1 若来自独立定位头，使用其二类计数；损毁输出折叠的定位指标单独标注。分类 F1 沿用 BRIGHT 规定的类别范围和平均方式，不能由现有几个 IoU 反推出。

所有本地控制实验应匹配输入、标签、像素前端、冻结状态、损失、数据流、更新预算、种子与概率解码。Lovász-Softmax 提供 IoU 优化代理[39]；若采用 AdamW，应记录其解耦权重衰减及实际运行设置[40]。现有总体比较包含公开基准和用户确认的本地 Test 汇总，二者标明来源；新控制实验尚无对应计数，统一标为“待测”，不是零分或预估成绩。

B. 总体定量结果及多灾种定性比较

表 1 首先给出总体结果。用户已确认 MPF 行来自图中 best_val_miou.pth 权重在完整 Test 上的既有汇总，其四类 mIoU 为 68.54%，定位 F1、分类 F1 和 OA 分别为 90.70%、73.29%和 96.31%。其完好、受损、毁坏 IoU 分别为 76.24%、42.21%和 58.72%，说明损毁等级仍明显比背景和完好类别困难。完整检索框架 Ours 尚无与本文配置对应的全量结果，保留“待测”，不将 MPF 或旧 memory 行改名作为完整方法成绩。

表 1　BRIGHT 标准 Test 的总体比较（%）

方法	定位 F1	分类 F1	OA	四类 mIoU	背景 IoU	完好 IoU	受损 IoU	毁坏 IoU
UNet†	87.97	72.24	95.47	64.94	96.19	71.27	39.13	53.17
DeepLabV3+†	87.00	70.33	95.43	64.80	95.98	70.98	37.53	54.69
SiamAttnUNet†	88.16	70.13	95.45	64.26	96.14	71.90	35.06	53.92
SiamCRNN†	89.45	72.02	95.76	65.73	96.48	73.44	38.91	54.18
ChangeOS†	89.60	71.88	95.84	65.98	96.54	73.85	38.99	54.53
DamageFormer†	90.29	72.51	96.13	67.09	96.87	75.04	39.86	56.59
ChangeMamba†	90.90	72.70	96.22	67.63	96.96	75.59	40.05	57.91
MPF‡（本地 Test）	90.70	73.29	96.31	68.54	96.99	76.24	42.21	58.72
Ours（完整）	待测	待测	待测	待测	待测	待测	待测	待测

表注：†为 BRIGHT 原文表 5 公开报告[2]，‡为用户确认同一 MPF 权重的完整 Test 汇总，本轮未重新执行推理。图 5–8 的 MPF 与该行模型身份对应，但各外部模型图列的本地权重不自动等同于公开表格的运

行。SiamCRNN 原表报告 65.73%，打印分项均值为 65.7525%，此处保留原文并披露差异。来源不同的分数差作为报告值比较，不解释为同种子、同预算的独立模块增益。

与公开 DamageFormer 报告比较，MPF 的四类 mIoU 增加 1.45 个百分点；背景、完好、受损和毁坏 IoU 分别增加 0.12、1.20、2.35 和 2.13 个百分点。增量更多分布在受损和毁坏等级，而不是仅由背景提高驱动。定位 F1 和分类 F1 分别高 0.41 和 0.78 个百分点，OA 高 0.18 个百分点。这里的 IoU 差不能进一步区分 TP 增加、FP 下降或 FN 减少，原因分析还需要原始混淆矩阵和同像素预测。

与公开 ChangeMamba 报告比较，MPF 四类 mIoU 高 0.91 个百分点，受损 IoU 高 2.16 个百分点、毁坏 IoU 高 0.81 个百分点；但定位 F1 低 0.20 个百分点。因此，不宜表述为所有指标领先。MPF 前景三类均值为 (76.24＋42.21＋58.72)/3≈59.0567%，与 68.54%的差异来自是否包含背景；不能把前景与四类指标直接相减作为模型提升，也不能把 Val 前景成绩与 Test 四类成绩混作同口径比较。

与表 1 配合，图 5 保留 18 个真实测试裁窗，按地震与冲突、火山与山火、飓风/洪水/爆炸三个子图展示。每行各列使用相同坐标；模型列是总体方法集合的子集，因此 ChangeOS 或 ChangeMamba 未出现在图中不构成矛盾。最后一列统一标为 MPF，其来源记录绑定像素前端 best_val_miou.pth；不能因旧图写“Ours (A1)”就将它改称完整检索模型。

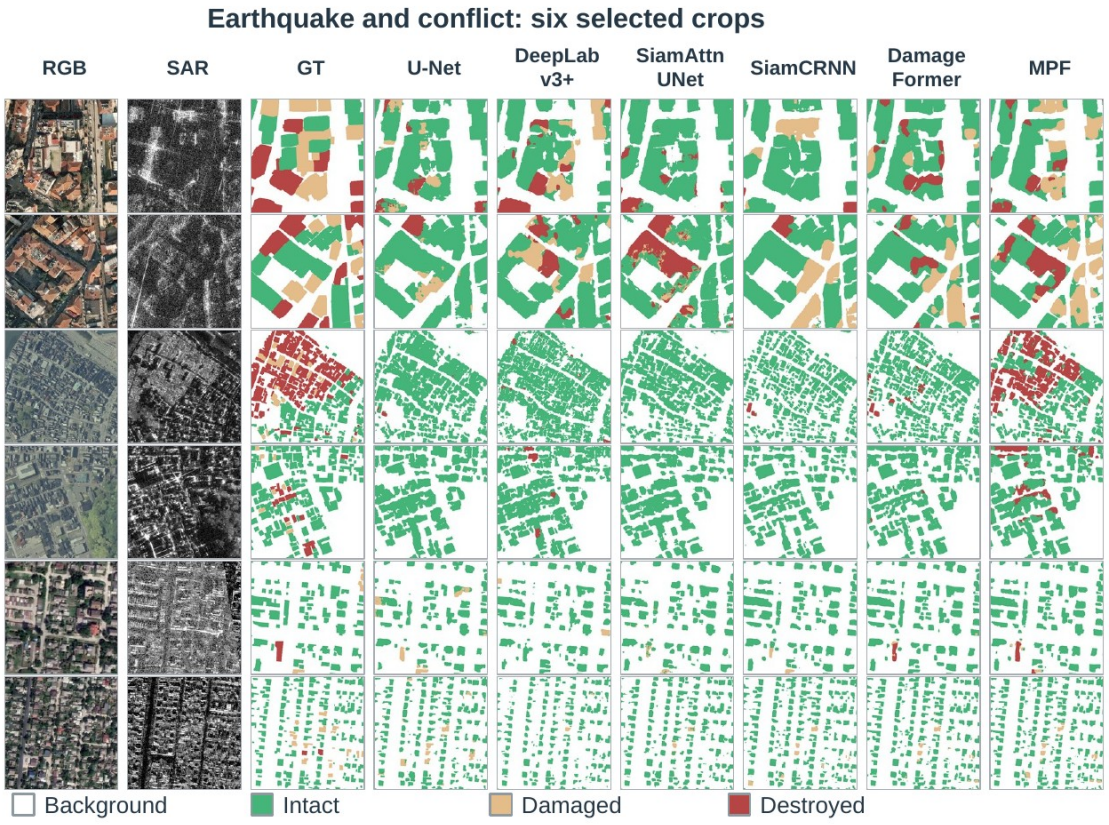


图 5(a)　多灾种所选测试裁窗：地震与冲突。每行依次为灾前 RGB、灾后 SAR、GT、U-Net、DeepLabv3+、SiamAttnUNet、SiamCRNN、DamageFormer、MPF。白、绿、浅棕、红依次表示背景、完好、受损、毁坏；每个子图 6 例。不同裁窗按相同显示尺寸排版，不表示相同物理尺度。

图 5(a)前两行的土耳其样例同时包含完好、受损与毁坏建筑。即使建筑范围相近，不同模型仍有不同等级分配：首行 DamageFormer 在所选屋顶附近保留红绿混合，而 MPF 呈现较多浅棕色受损区域。能登第三行具有成片毁坏标签，多数对照将相当部分判为绿色完好，MPF 在对应位置恢复较大范围红色；但绿色残留与边缘偏差仍然存在。乌克兰两行以完好为主，各模型主体范围接近，细小损毁仍有遗漏。由此可见，局部差异既有等级判断，也有定位，不宜概括为所有灾种一致改善。

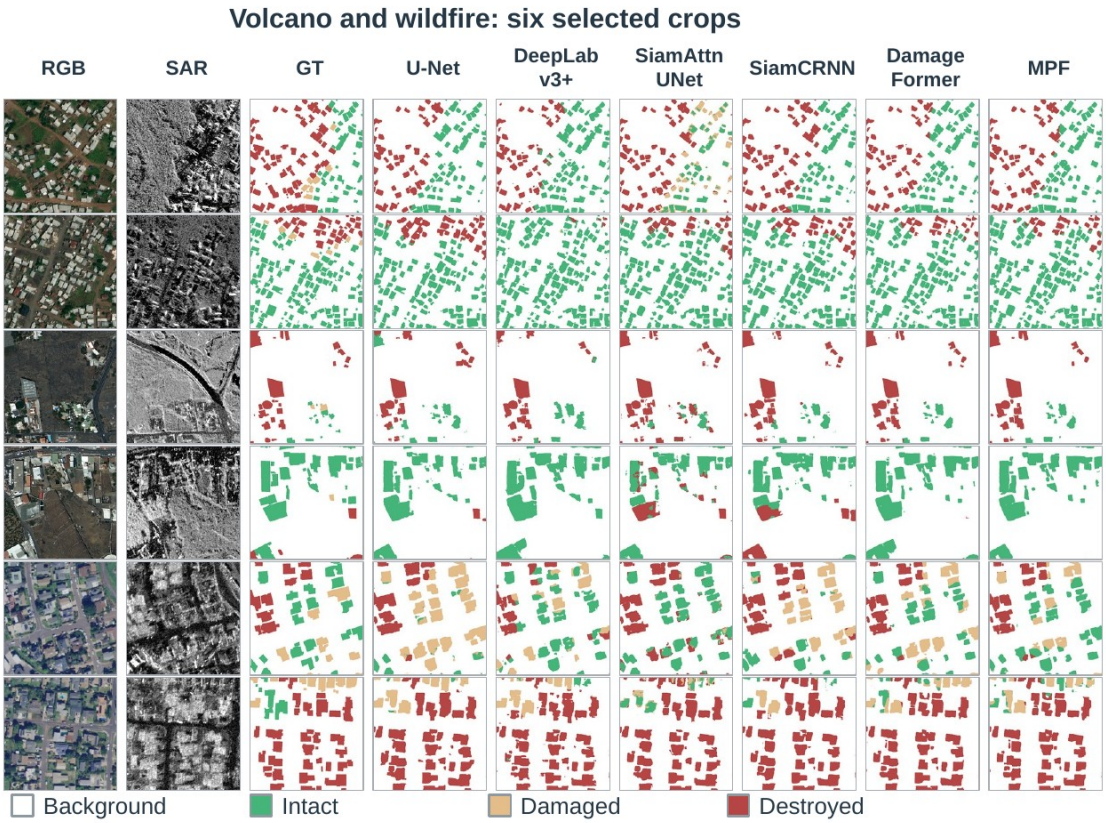


图 5(b)　多灾种所选测试裁窗：火山与山火。每行依次为灾前 RGB、灾后 SAR、GT、U-Net、DeepLabv3+、SiamAttnUNet、SiamCRNN、DamageFormer、MPF。白、绿、浅棕、红依次表示背景、完好、受损、毁坏；每个子图 6 例。不同裁窗按相同显示尺寸排版，不表示相同物理尺度。

图 5(b)中的刚果样例包含相邻完好与毁坏建筑，应比较红绿交界与 GT，而不是把红色更多当作更好。La Palma 具有大面积背景，部分模型在稀疏建筑附近产生附加损毁斑块，需计入背景假阳性。夏威夷山火包含受损与毁坏混合建筑，各模型仍有等级互换和漏检，MPF 也未消除这些错误。这些例子提示，图像解释应同时包含救回、误改和背景误报，避免只报告成功区域。

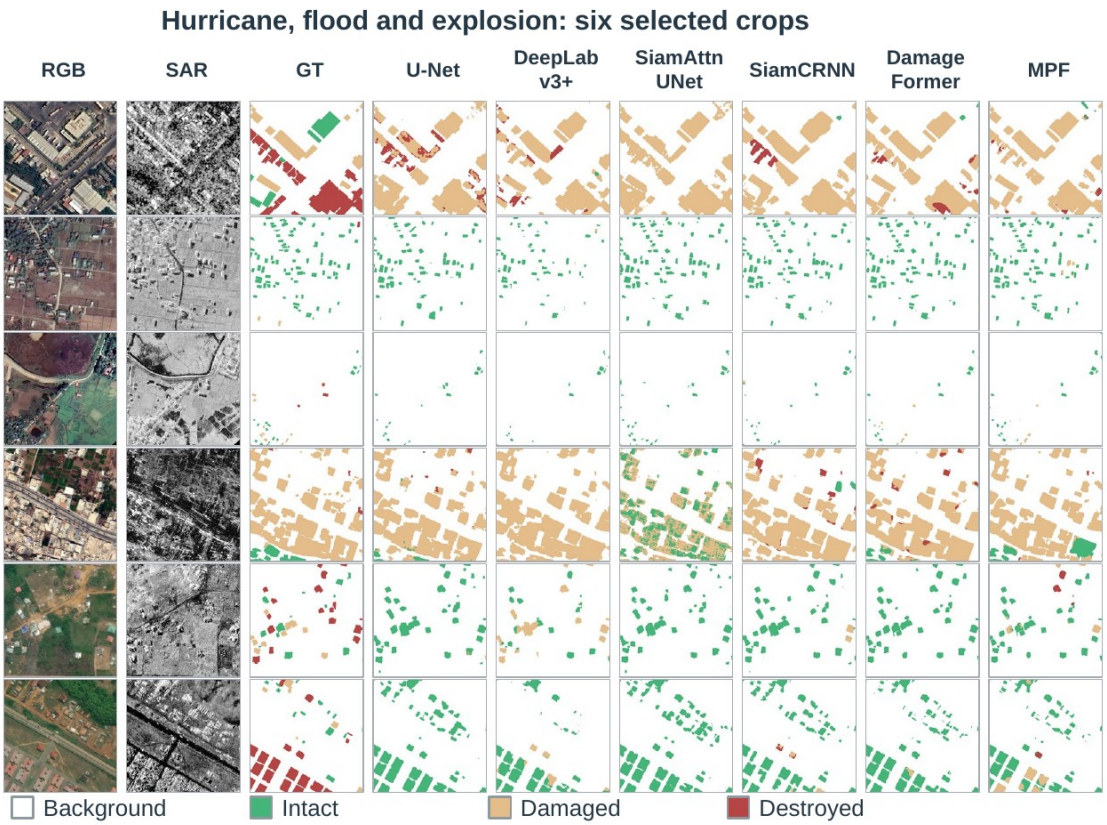


图 5(c)　多灾种所选测试裁窗：飓风、洪水与爆炸。每行依次为灾前 RGB、灾后 SAR、GT、U-Net、DeepLabv3+、SiamAttnUNet、SiamCRNN、DamageFormer、MPF。白、绿、浅棕、红依次表示背景、完好、受损、毁坏；每个子图 6 例。不同裁窗按相同显示尺寸排版，不表示相同物理尺度。

图 5(c)墨西哥样例的大面积受损主体在多数方法中能够保留，但局部毁坏仍有遗漏。缅甸两行建筑稀疏且较小，缩略图不足以评价损毁恢复，需要同坐标放大。利比亚样例中受损区域会混入完好或毁坏；Bata 样例中仍可见毁坏被判为完好，MPF 也存在剩余错误。图 5 所示是具体错误形态，不能由 18 个所选裁窗推出整个 Test、事件或稀有等级的总体提升。

表 1 与图 5 互为补充：已确认 MPF 的全量 Test 成绩为 68.54%，图 5 说明该像素前端在所选位置呈现何种差异。图像选例不能解释总体增量中的全部像素来源；尤其毁坏大块恢复、受损屋顶一致性和背景误报可能同时出现。完整框架的定量及定性结论，仍需在相同 Test 协议和同一窗口补充 Ours 实际输出，不能仅修改图列名称。

C. 递进配置汇总与三类局部误差

表 2(a)保留 base、region、roi、memory 四个既有配置。用户已确认 roi 对应 MPF 像素前端及图中权重，因此统一写为“MPF（原 roi）”；不再把它自动当成本文结构 Adapter 的单独开关版本。其他旧配置的前端、Q、Reader、支持规则和预算仍需运行记录确认。这张表用于分析既有报告的变化，不能直接代替表 3–6 针对当前新框架的机制消融。

表 2(a)　既有配置结果汇总（%，MPF 身份已由用户确认）

配置	定位 F1	分类 F1	OA	四类 mIoU	背景 IoU	完好 IoU	受损 IoU	毁坏 IoU
基础模型（base）	90.29	72.51	96.12	67.09	96.87	75.04	39.86	56.59
区域配置（region）	90.36	72.72	96.28	67.84	96.81	75.23	41.00	58.33
MPF（原 roi）	90.70	73.29	96.31	68.54	96.99	76.24	42.21	58.72
历史检索（memory）	90.91	74.40	96.12	待核	96.89	76.24	43.84	61.59

表注：除已确认的 MPF 身份外，旧配置的实际开关仍待记录绑定。memory 旧报四类 mIoU 为 69.62%，但打印 IoU 的算术均值为 69.64%，不能通过常规两位小数舍入解释，故该单元格标为“待核”。本轮不选择其中一个作为实测结果。base 的 OA=96.12%与公开 DamageFormer 的 96.13%分属现有记录，保留差别而不强行修改。

按既有报告计算，region 相对 base 的四类 mIoU 由 67.09%变为 67.84%，增加 0.75 个百分点；受损和毁坏 IoU 分别增加 1.14 和 1.74 个百分点，背景下降 0.06 个百分点。MPF 相对 region 的四类 mIoU 高 0.70 个百分点，完好、受损、毁坏分别高 1.01、1.21 和 0.39 个百分点，背景也高 0.18 个百分点。这些记录显示不同配置的类别变化并不相同，但尚不能确定变化完全来自区域汇总或建筑加权，因为前端、训练流和读出是否保持一致还需要核对。

旧 memory 相对 MPF 的受损与毁坏 IoU 分别高 1.63 和 2.87 个百分点，完好同为 76.24%，背景低 0.10 个百分点；分类 F1 高 1.11 个百分点，但 OA 低 0.19 个百分点。因而旧报告体现的是损毁等级与背景/总体准确率之间的取舍，不能写成“所有指标单调提高”。四类 mIoU 冲突解决前，不报告 memory 的总体增益；更不能用这行代替当前跨事件监督排序的完整框架。

表 2(b)补充从打印分项 IoU 直接推算的前景均值，明确它属于算术派生，不是新的服务器评测。四阶段前景均值依次约为 57.1633%、58.1867%、59.0567%和 60.5567%。最后一项反映旧 memory 行后三个报告分项的关系，仍不解决其四类 mIoU 来源冲突；也不验证真实案例、排序空间或 Reader 中的哪一部分起作用。

表 2(b)　由报告分项 IoU 推算的前景均值与差值

既有配置	前景 mIoU%（派生）	相对 base 差值 pp	相邻配置差值 pp
base	57.1633	+0.0000	不适用
region	58.1867	+1.0233	+1.0233
MPF（原 roi）	59.0567	+1.8933	+0.8700
memory（旧报告）	60.5567	+3.3933	+1.5000

图 6–图 8 紧接递进表，分别分析毁坏漏判、屋顶等级混杂和稀疏目标恢复。三图目前都只比较 DamageFormer 与 MPF，能解释像素前端的局部现象；它们没有 region/roi/memory 各阶段列，不能一一对应三个模块。补齐同一窗口各阶段真实预测后，才能进一步把图像现象与阶段增量连接。蓝框只定位放大窗口，不表示注意力、建筑实例或检索返回区域。

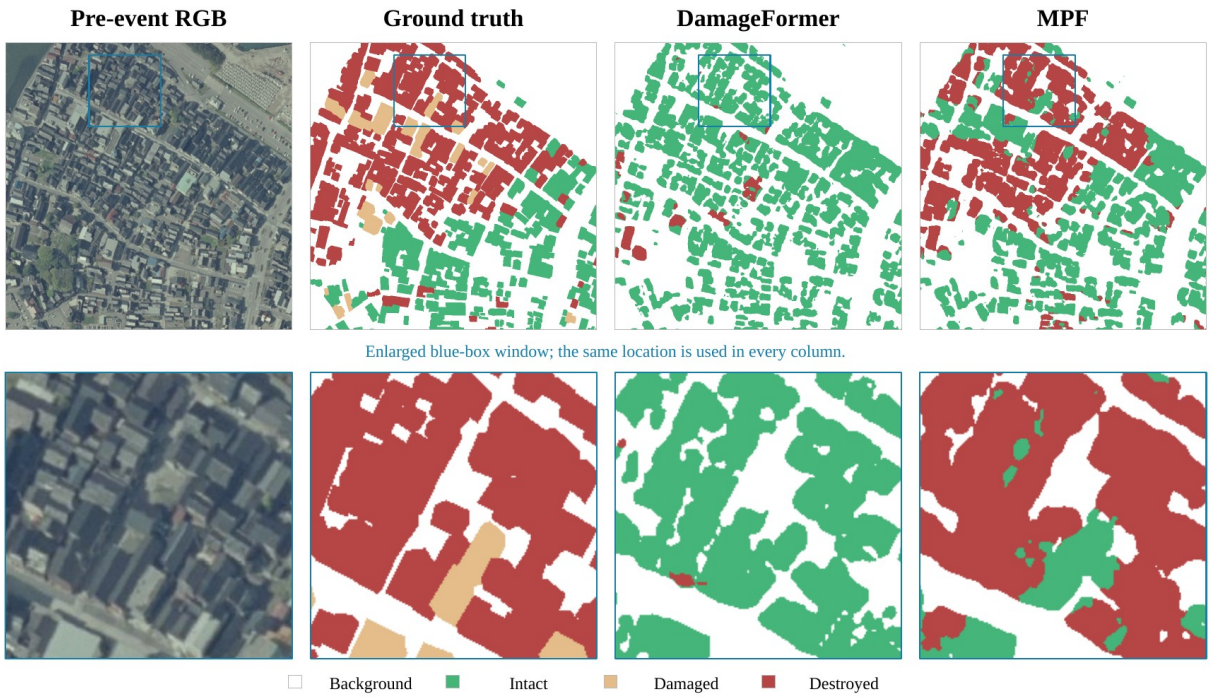


图 6　能登地震：毁坏被判为完好的局部比较。上排为灾前 RGB、GT、DamageFormer、MPF，下排为相同蓝框窗口的放大。样例 noto-earthquake；类别配色与图 5 一致。

图 6 的 GT 将蓝框内多栋建筑标为毁坏，DamageFormer 在主体范围主要输出绿色完好，MPF 在相同位置输出较大面积红色，与参考等级更接近。这里主要是 Destroyed→Intact 混淆减少，不是 Damaged 类别恢复。红色预测较多只有在与真实毁坏位置相符时才是救回；落入 GT 背景或其它等级的部分应计为误报。MPF 仍有绿色残留和建筑间隔偏差，因此该例同时包含局部纠错与剩余错误，不能写成全部建筑结构已恢复。

这一现象与表 1 中 MPF 的毁坏 IoU 高于公开 DamageFormer 报告方向一致，但选取的能登窗口并不能证明总体 2.13 个百分点的来源，更不能把差异归于图中未展示的 Memory。后续应在该固定窗口累积 Destroyed 的 TP、FP、FN，并相对同一 DamageFormer 预测统计毁坏类救回、误改及背景→建筑 FP；有实例标注时再讨论建筑内一致性。

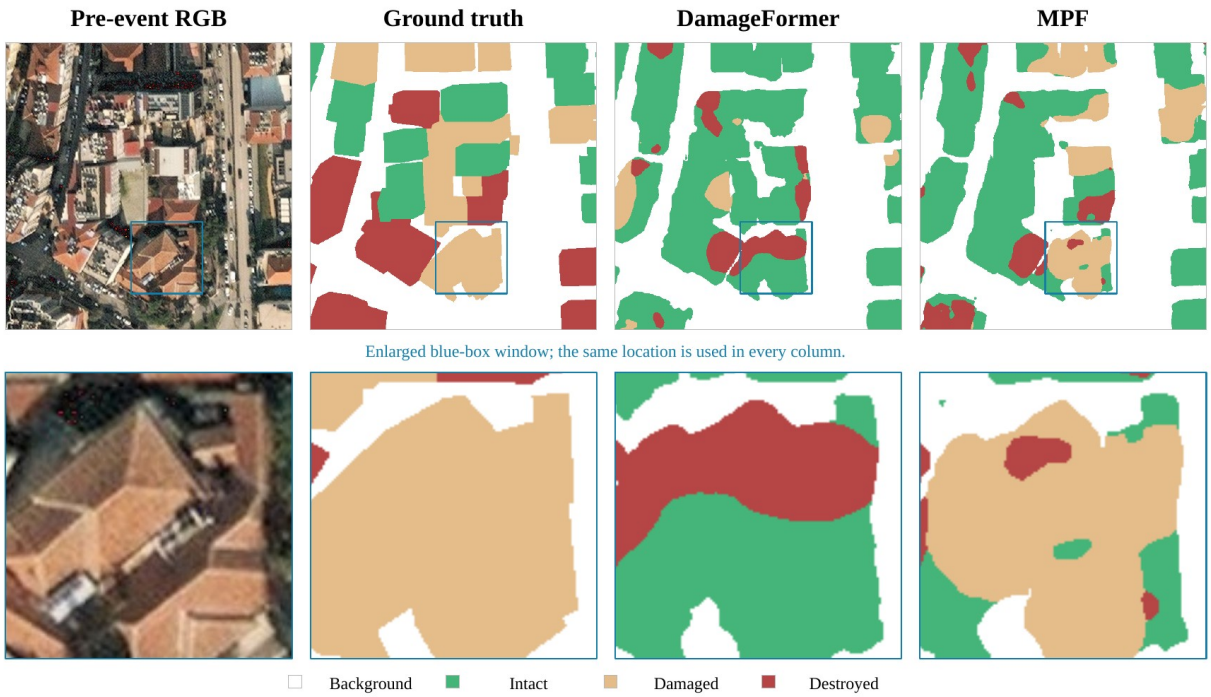


图 7　土耳其地震：受损屋顶内部等级混杂。上排依次为灾前 RGB、GT、DamageFormer、MPF，下排为同一蓝框屋顶放大。样例 turkey-earthquake；浅棕、绿、红分别为受损、完好、毁坏。

图 7 的参考标签将蓝框屋顶主体标为受损，DamageFormer 在同一屋顶内分配了绿色完好与红色毁坏，MPF 则以浅棕色覆盖较多主体，体现所选位置的 Damaged 等级恢复。MPF 仍有红色残留、绿色小孔和边缘扩张，说明等级判断与建筑轮廓没有同时完全解决。GT 在这里采用单一建筑等级，因此预测中的多色混合是相对标注的不一致，不能反过来描述为模型识别出了真实的多种局部损毁程度。

该例能够解释受损 IoU 可能如何提高，却不能从截图计算增量。尤其将原本的红色误判变为浅棕色可提高 Damaged TP，同时可能改变 Destroyed FP；轮廓外浅棕扩张又会增加 Damaged FP。需把这几类变化分开统计，才能判断局部 IoU 变化来自等级纠正还是范围扩张。图片不含当前 Q 相容项或 Adapter 的关闭版本，不能作为两项结构机制的独立证据。

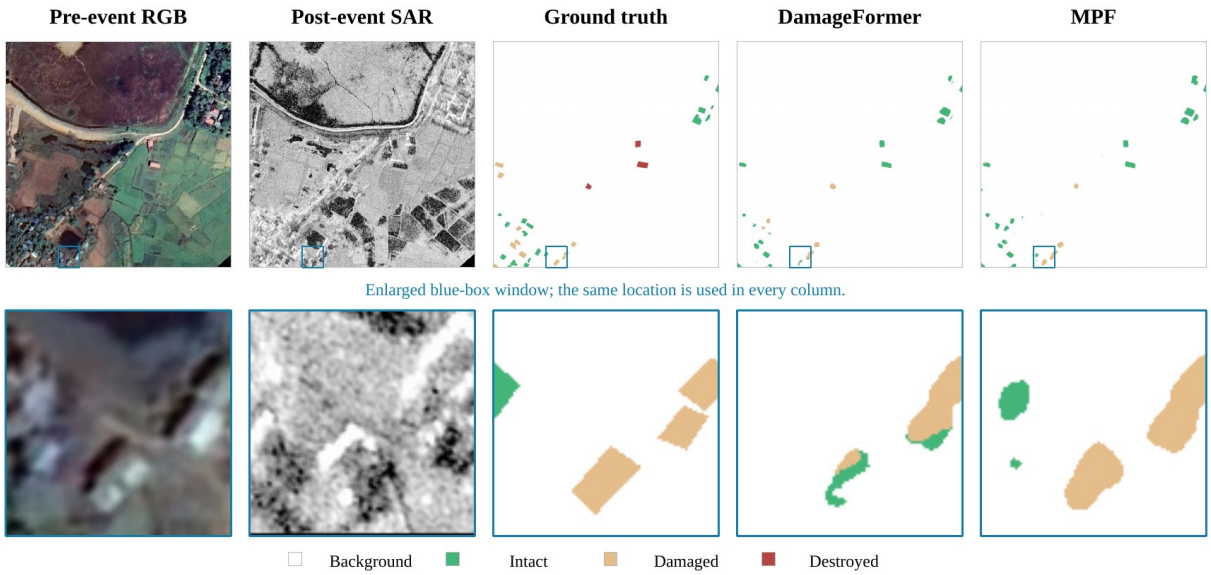


图 8　缅甸飓风：稀疏受损目标恢复与背景误报。上排为灾前 RGB、灾后 SAR、GT、DamageFormer、MPF，下排为相同 96×96 原始像素窗口。样例 myanmar-hurricane；原图局部分数待原始计数复核。

图 8 的 96×96 放大窗口包含两个浅棕色受损目标。DamageFormer 对其中一目标仅保留较小受损区域并混入绿色，MPF 恢复了更完整的浅棕主体；其左侧同时出现额外绿色斑块，相应 GT 主要是背景。因而，这个例子的准确表述是"部分受损目标恢复更完整，但建筑假阳性仍存在"。缩略整图中的受损像素较少，必须保持所有列同一原始窗口和缩放，不能用显示后的目标大小推断真实尺度。

稀疏小目标情况下，少量像素即可明显改变局部 IoU，不能把单窗变化外推为整个事件或 Test 的增益。后续应同时报告 Damaged 召回、Damaged FP、背景→建筑 FP 和有效目标像素数，并与图 6 大块毁坏、图 7 屋顶内部混杂相区分。图 8 现有预测来自 MPF，不提供检索支持 ID 或读取干预，故仍不能证明历史案例是其恢复原因。

三幅图共同表明，定位、等级和背景误报需要分开解释。它们保留了既有可追溯预测，而不以模拟热图或预估分数替代实测。真正的机制证明应使用下节控制实验；新的 Q/Adapter/支持开关预测应保持图 6–图 8 同一图像与裁窗，不另挑更有利区域。

D. 三项设计的控制实验与结果填写位置

当前表 3–6 是针对本文设计的待完成控制实验。既有 MPF 及旧 memory 结果来自不同计算路径，不能按名称相似直接回填。没有实测依据时无法给出可信的期望分数；本稿以"待测"保留位置，并明确何种结果支持或不支持相应判断。可能的正向、负向或无变化趋势在配套分析说明中作为假设讨论，不写成实验结论。

1) 区域成员与区域内容是否分别有效

表 3(a)　建筑相容项×结构适配的二因素控制

B→Q	结构适配	四类 mIoU%	前景 mIoU%	受损 IoU%	毁坏 IoU%	混合率%	边缘错率%
关	关	待测	待测	待测	待测	待测	待测
开	关	待测	待测	待测	待测	待测	待测
关	开	待测	待测	待测	待测	待测	待测
开	开	待测	待测	待测	待测	待测	待测

四组固定 MPF、区域预算、数据流与更新次数，统一将区域特征经 Q 直接回投后与 F 联合分类，不设 Reader 或支持槽。关闭 B→Q 仅将新增相容项权重置零；关闭 Adapter 仍保留基础内容投影及输出维度。两种 Q 下分别比较 Adapter 的有无，两种 Adapter 设置下分别比较 B→Q 的有无；交互为"联用−仅相容项−仅适配＋基准"。各差值及交互均待测。若相容项仅降低混合率而分类无变化，只支持区域组织改变；若仅联用提高，不应宣称两项各自独立有效。

混合率在有效区域中统计 Q 加权 GT 建筑比例介于 0.1 与 0.9 的区域比例，同时报告有效区域数、质量分布和前景等级混合。边缘错率在预先固定宽度的 GT 建筑边界带内计算四类错误及分母，GT 仅用于评价。本轮不新增或修改图片；后续结构诊断需导出同窗口预测 B、Q 开关、b(Q)、H(Q)及四组分类结果，不能以 GT 边界替代模型响应。

表 3(b)　固定同一 Q 的内容条件与容量对照

适配设置	活跃参数 M	前景 mIoU%	受损 IoU%	毁坏 IoU%	边缘错率%
普通内容 Adapter	待核	待测	待测	待测	待测
完整 B ·b(Q) ·H(Q)	待核	待测	待测	待测	待测
去显式 B	待核	待测	待测	待测	待测
去 b(Q)	待核	待测	待测	待测	待测
去 H(Q)	待核	待测	待测	待测	待测

表 3(b)固定同一 Q 和融合输入，在本协议下训练完整条件与各去除版本；普通 Adapter 匹配活跃计算和容量，不能用闲置参数凑数。去显式 B 不会移除其经 Q 传递的影响。完整条件、普通 Adapter 及逐项去除的差值均待测。如果完整条件只优于无 Adapter 而不优于普通 Adapter，证据更接近额外内容处理容量，而非结构条件本身；若去某一条件无变化，也不必断言它无信息，仍需检查与其它条件的冗余及统计稳定性。

2) 当前区域、读取容量和真实历史案例是否有增量

表 4　信息来源及读取方式对照

配置	当前区域	真实 Train 支持	选择方式	四类 mIoU%	前景 mIoU%	受损 IoU%	毁坏 IoU%
像素头适配	无	无	无	待测	待测	待测	待测
像素–区域融合	有	无	直接回投	待测	待测	待测	待测
参数化支持	有	无	可学习向量	待测	待测	待测	待测
余弦检索	有	有	原始 T 余弦	待测	待测	待测	待测
跨事件监督检索	有	有	学习投影	待测	待测	待测	待测

表 4 固定区域前端与库成员，匹配初始化、损失、更新流和预算。像素–区域相对像素头适配检验当前图像区域上下文；参数化支持检验 Reader 及学习到的全局先验；真实 Train 案例相对参数化支持检验历史内容；监督相对余弦比较完整检索配置。上述成绩待测。可学习向量不是空信息，独立训练 Reader 的差异也包含适应与随机性。只有真实案例优于容量匹配对照，且固定读取器替换支持仍显示相关性作用，才能进一步主张检索信息有增量。

3) 支持更相关是否真正带来分类改善

表 5　固定读取器、联合头和库，仅替换邻居 ID

支持选择	类宏 P@8%	受损 Hit@8%	毁坏 Hit@8%	救回像素	误改像素	前景 mIoU%
原始余弦	待测	待测	待测	待测	待测	待测
跨事件监督投影	待测	待测	待测	待测	待测	待测
随机合格支持	待测	待测	待测	待测	待测	待测

训练时使用预先固定比例混合两种排序邻居的共同 Reader，评价固定其权重、Q、库、K 和排除规则，仅改变返回 ID，并按 ID 读取整条未投影记录。若不采用混合训练，则做“Reader 训练排序×评价排序”的完整交叉替换。救回和误改统一相对同协议 MPF 预测：前者为 MPF 错误而该配置正确，后者为 MPF 正确而该配置错误。MPF 取同次前向原生分类输出并固定解码，避免额外分类器调用引入路径差异。检索固定 K=8；P@8 仅在主类纯度≥0.8 的查询上计算，每个查询以 8 个返回槽位为分母，失效或未填满槽位计未命中，并另报有效槽位率。按完好、受损、毁坏分别给出查询数与 P@8，再作前景类别宏平均；事件宏平均单列，不与类宏平均混合。Hit@8 在对应主类查询中统计至少一条真实合格同类支持的比例，以该类全部合格查询数为分母，并报告候选库中有无同类可用记录。背景查询另报，缺少查询的组记为不适用而不默默改变平均规则。排序相关性与固定读取器的前景变化均待测。若前者改善而后者无增量，结论只限邻居选择，不能写成分类收益。

后续检索可视化应对同一查询列出两种排序真实返回的 Train RGB/SAR、ID、事件、软标签和排除记录，并关联基础/最终预测及救回、误改；本轮不新增该图。相似度不是校准置信度，两个空间的分数也不能直接比较。改善、持平和退化案例均应保留。若近邻主类更一致而最终分割不变，说明排序质量改善尚未转化为任务收益，不能凭邻居图宣布完整方法有效。

E. 补充实验、稳定性与数据需求

表 6　支持内容消融与固定权重干预

检验项	训练/评价操作	前景 mIoU%	受损 IoU%	毁坏 IoU%
完整支持	同预算重训基准	待测	待测	待测
去软标签	固定 ID，同预算重训	待测	待测	待测
去事件 ID	固定 ID，同预算重训	待测	待测	待测
去灾种	固定 ID，同预算重训	待测	待测	待测
去几何	固定 ID，同预算重训	待测	待测	待测
随机支持	固定权重，多次合格抽样	待测	待测	待测
标签置换	固定权重，保留标签边际分布	待测	待测	待测
关闭支持路径	固定权重，标注分布外干预	待测	待测	待测

重训消融评价该信息在训练中的增量，固定权重扰动评价已训练模型的依赖与脆弱性，二者不混作同一种贡献。如果去标签重训不改变结果，不能声称历史标签必需；随机支持与检索支持相近，则不能认定近邻相关性是主要原因。关闭支持是干预而非公平容量基线，其负向变化也不单独构成因果证明。

稳定性至少采用 3 个预先确定种子，报告均值±标准差和同种子配对增量；必要时在图像或事件层配对重采样，不把相关像素当独立样本。逐事件先累计矩阵再评价，同时报告事件等权平均与全局结果。推理成本在相同线程、精度、预热和同步下测量，共享 CPU 限流的墙钟时间不能当作算法开销。当前均值、方差、事件结果和成本未提供，记录于配套待填表，不能从单次分数估计。

下一步优先补充各配置的完整评估 JSON 与 4×4 矩阵，解决 memory 总体指标冲突，并绑定前端/Q/Reader/支持与预算；之后提供相同窗口的 GT、原标签 PNG 及各阶段预测，再计算救回和误改；最后补 Train 支持轨迹、训练选型、种子和资源记录。已有小 JSON、清单与统计计数即可开始核验，不必先上传全部大权重或重训。历史双槽 Top64 实验单独整理在配套分析说明中，不混入本稿 Top-8 监督检索的控制表。

V. 结论

本文将光学–SAR 建筑损毁评估中的区域成员、区域内容和历史支持选择组织为连续处理路径：预测建筑概率约束局部软归属，分区状态调节融合内容，跨事件类别监督改变支持排序，增强区域经相同归属回投并与像素内容联合分类。总体表、递进表和三类局部错误描述分别对应全量性能、配置变化与具体预测行为，控制实验进一步检验结构与历史支持的作用。

已确认 MPF 像素前端在完整 Test 上的四类 mIoU 为 68.54%，报告分项推算的前景 mIoU 约为 59.06%；相对公开 DamageFormer 报告的四类 mIoU 差为 1.45 个百分点。该比较体现既有像素前端的报告性能，不能作为新增区域编码或监督检索的独立收益。完整框架、二因素控制及支持干预仍待实测。预测建筑误差、区域混合与不相关案例可能引发误改；只有同协议控制、真实检索记录和多种子稳定性共同支持时，才形成完整方法的效果结论。

参考文献

[1] Ritwik Gupta, Bryce Goodman, Nirav Patel, Rachel Hosfelt, Sajal Sajeev, Eric Heim, Jigar Doshi, Keane Lucas, Howie Choset, Matthew Gaston. Creating xBD: A Dataset for Assessing Building Damage from Satellite Imagery. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2019.

[2] Hongruixuan Chen, Jian Song, Olivier Dietrich, Clifford Broni-Bediako, Weihao Xuan, Junjue Wang, Xinlei Shao, Yimin Wei, Junshi Xia, Cuiling Lan, Konrad Schindler, Naoto Yokoya. BRIGHT: a globally distributed multimodal building damage assessment dataset with very-high-resolution for all-weather disaster response. Earth System Science Data, 2025, 17(11): 6217–6253. DOI: 10.5194/essd-17-6217-2025.

[3] Zhuo Zheng, Yanfei Zhong, Junjue Wang, Ailong Ma, Liangpei Zhang. Building damage assessment for rapid disaster response with a deep object-based semantic change detection framework: from natural disasters to man-made disasters. Remote Sensing of Environment, 2021, 265: 112636. DOI: 10.1016/j.rse.2021.112636.

[4] Hongruixuan Chen, Edoardo Nemni, Sofia Vallecorsa, X. Li, C. Wu, L. Bromley. Dual-Tasks Siamese Transformer Framework for Building Damage Assessment. IGARSS 2022 – 2022 IEEE International Geoscience and Remote Sensing Symposium, 2022: 1600–1603. DOI: 10.1109/IGARSS46834.2022.9883139.

[5] Hongruixuan Chen, Jian Song, Chengxi Han, Junshi Xia, Naoto Yokoya. ChangeMamba: Remote Sensing Change Detection With Spatiotemporal State Space Model. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1–20. DOI: 10.1109/TGRS.2024.3417253.

[6] Zhuo Zheng, Yanfei Zhong, Liangpei Zhang, Marshall Burke, David B. Lobell, Stefano Ermon. Towards transferable building damage assessment via unsupervised single-temporal change adaptation. Remote Sensing of Environment, 2024, 315: 114416. DOI: 10.1016/j.rse.2024.114416.

[7] James Currie, Karin Reinke. Assessing the transferability of post-disaster building damage assessment using synthetic aperture radar and machine learning. International Journal of Disaster Risk Reduction, 2026, 136: 106048. DOI: 10.1016/j.ijdrr.2026.106048.

[8] Jonathan Long, Evan Shelhamer, Trevor Darrell. Fully Convolutional Networks for Semantic Segmentation. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015: 3431–3440.

[9] Olaf Ronneberger, Philipp Fischer, Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015, 2015: 234–241. DOI: 10.1007/978-3-319-24574-4_28.

[10] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, Hartwig Adam. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. European Conference on Computer Vision (ECCV), 2018.

[11] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. Deep Residual Learning for Image Recognition. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 770–778. DOI: 10.1109/CVPR.2016.90.

[12] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, Baining Guo. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. IEEE/CVF International Conference on Computer Vision (ICCV), 2021.

[13] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, Ping Luo. SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers. Advances in Neural Information Processing Systems (NeurIPS), 2021.

[14] Hongruixuan Chen, Chen Wu, Bo Du, Liangpei Zhang, Le Wang. Change Detection in Multisource VHR Images via Deep Siamese Convolutional Multiple-Layers Recurrent Neural Network. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(4): 2848–2864.

[15] Yongjun He, Jinfei Wang, Chunhua Liao, Xin Zhou, Bo Shan. MS4D-Net: Multitask-Based Semi-Supervised Semantic Segmentation Framework with Perturbed Dual Mean Teachers for Building Damage Assessment from High-Resolution Remote Sensing Imagery. Remote Sensing, 2023, 15(2): 478. DOI: 10.3390/rs15020478.

[16] Zhengtao Xie, Zifan Zhou, Xinhao He, Yuguang Fu, Jiancheng Gu, Jiandong Zhang. Methodology for Object-Level Change Detection in Post-Earthquake Building Damage Assessment Based on Remote Sensing Images: OCD-BDA. Remote Sensing, 2024, 16(22): 4263. DOI: 10.3390/rs16224263.

[17] R. Achanta, A. Shaji, K. Smith, A. Lucchi, P. Fua, S. Süsstrunk. SLIC Superpixels Compared to State-of-the-Art Superpixel Methods. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 34(11): 2274–2282.

[18] Varun Jampani, Deqing Sun, Ming-Yu Liu, Ming-Hsuan Yang, Jan Kautz. Superpixel Sampling Networks. European Conference on Computer Vision, 2018.

[19] Fengting Yang, Qian Sun, Hailin Jin, Zihan Zhou. Superpixel Segmentation with Fully Convolutional Networks. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.

[20] Julien Walther, Rémi Giraud, Michaël Clément. Superpixel Anything: A General Object-Based Framework for Accurate Yet Regular Superpixel Segmentation. British Machine Vision Conference, 2025.

[21] Yuhui Yuan, Xilin Chen, Jingdong Wang. Object-Contextual Representations for Semantic Segmentation. European Conference on Computer Vision, 2020.

[22] Hengshuang Zhao, Jianping Shi, Xiaojuan Qi, Xiaogang Wang, Jiaya Jia. Pyramid Scene Parsing Network. IEEE Conference on Computer Vision and Pattern Recognition, 2017.

[23] Jun Fu, Jing Liu, Haijie Tian, Yong Li, Yongjun Bao, Zhiwei Fang, Hanqing Lu. Dual Attention Network for Scene Segmentation. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 3146–3154.

[24] Xiaolong Wang, Ross Girshick, Abhinav Gupta, Kaiming He. Non-local Neural Networks. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018.

[25] Jie Hu, Li Shen, Gang Sun. Squeeze-and-Excitation Networks. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018.

[26] Peihua Li, Jiangtao Xie, Qilong Wang, Wangmeng Zuo. Is Second-order Information Helpful for Large-scale Visual Recognition?. IEEE International Conference on Computer Vision, 2017.

[27] Yanfeng Zhang, Zhiwu Gao, Ying Dai, Yu Wu, Lei Zhang, Xingxing Han, Zhenxuan Liu. WANet: A Wavelet-Attention Network for Accurate Ditch Extraction in Remote Sensing Imagery. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2026, 19: 17042–17054. DOI: 10.1109/JSTARS.2026.3693082.

[28] Ethan Perez, Florian Strub, Harm de Vries, Vincent Dumoulin, Aaron Courville. FiLM: Visual Reasoning with a General Conditioning Layer. Proceedings of the AAAI Conference on Artificial Intelligence (AAAI), 2018.

[29] Wenguan Wang, Tianfei Zhou, Fisher Yu, Jifeng Dai, Ender Konukoglu, Luc Van Gool. Exploring Cross-Image Pixel Contrast for Semantic Segmentation. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2021: 7303–7313.

[30] Tianfei Zhou, Wenguan Wang, Ender Konukoglu, Luc Van Gool. Rethinking Semantic Segmentation: A Prototype View. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022.

[31] Jake Snell, Kevin Swersky, Richard Zemel. Prototypical Networks for Few-shot Learning. Advances in Neural Information Processing Systems (NIPS), 2017.

[32] Han-Jia Ye, Hexiang Hu, De-Chuan Zhan, Fei Sha. Few-Shot Learning via Embedding Adaptation with Set-to-Set Functions. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020: 8808–8817.

[33] Renrui Zhang, Wei Zhang, Rongyao Fang, Peng Gao, Kunchang Li, Jifeng Dai, Yu Qiao, Hongsheng Li. Tip-Adapter: Training-free Adaption of CLIP for Few-shot Classification. European Conference on Computer Vision (ECCV), 2022.

[34] Xun Wang, Haozhi Zhang, Weilin Huang, Matthew R. Scott. Cross-Batch Memory for Embedding Learning. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020.

[35] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, Ross Girshick. Momentum Contrast for Unsupervised Visual Representation Learning. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020: 9729–9738.

[36] Xinlong Wang, Rufeng Zhang, Chunhua Shen, Tao Kong, Lei Li. Dense Contrastive Learning for Self-Supervised Visual Pre-Training. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021.

[37] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, Dilip Krishnan. Supervised Contrastive Learning. Advances in Neural Information Processing Systems (NeurIPS), 2020.

[38] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin. Attention Is All You Need. arXiv preprint arXiv:1706.03762, 2017. https://arxiv.org/abs/1706.03762.

[39] Maxim Berman, Amal Rannen Triki, Matthew B. Blaschko. The Lovász-Softmax Loss: A Tractable Surrogate for the Optimization of the Intersection-Over-Union Measure in Neural Networks. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018: 4413–4421. DOI: 10.1109/CVPR.2018.00464.

[40] Ilya Loshchilov, Frank Hutter. Decoupled Weight Decay Regularization. International Conference on Learning Representations (ICLR), 2019.